

# La música como expresión de nuestro electroencefalograma

Nicolás Adrián Kis – Ingeniería Informática

Gabriel Hugo Taboada. Ingeniero. – U. de Palermo - TUTOR - TFG

**Abstract--** Dejemos que nuestro cerebro hable por nosotros sin intervención del lenguaje. La idea es crear una aplicación que nos haga presente físicamente - a través de canciones - nuestro estado de ánimo en un momento particular del tiempo sin que nosotros lo hagamos de manera consiente. Para hacer esto posible se plantea el desarrollo de un sistema que tome datos de un dispositivo denominado electroencefalograma, los procese, analice, evalúe y encuentre una canción acorde a nuestro estado de ánimo en dicho instante del tiempo del estudio.

El electroencefalograma mencionado será procesado debidamente en base a la clasificación de las longitudes de onda (producto de la lectura EEG) que lo forman, a un modelo 2D de emociones [1]. Según la clasificación producto de esta lectura EEG del sujeto, se determinará el método para buscar aquellas canciones que mejor representen el estado de ánimo del mismo en el momento de la lectura EEG.

**La música como efecto** – “Music is sound organized in varying rhythmic, melodic and dynamic patterns performed on different instruments.” [2]. Cada día los sonidos nos rodean, y cada día elegimos música para alterar nuestro estado de ánimo porque sabemos que generan algo en nosotros.

Este trabajo busca entregar una aplicación que elija canciones por nosotros en base a nuestro estado de ánimo.

## I. NOMENCLATURA

EEG = Electroencefalograma  
SAM = Self-assessment manikin  
SVM = Support Vector Machine

## II. INTRODUCCIÓN

EN el presente documento estaremos presentando una manera de analizar y procesar la salida de un electroencefalograma (de ahora en adelante EEG) para poder catalogarlo de una perceptiva, evitando la lectura de gráficos para ver qué dice nuestro EEG sobre nuestro estado de ánimo. La metodología y la técnica en la que se realiza el mismo no será una variable en nuestro estudio, sino será utilizada como un parámetro que decidimos fijar en base a lo que se cree conveniente para la correcta posterior evaluación de las emociones.

El objetivo es encontrar un conjunto acotado de canciones que mejor represente nuestro estado de ánimo en el momento en el que se realiza el estudio EEG sobre dicho sujeto.

## III. CASO DE ESTUDIO

### A. Dataset

Los datos utilizados para el experimento que se utiliza en este trabajo fueron extraídos de una base de datos existentes denominada DEAP <sup>(1)</sup>, en donde se obtienen los datos de la lectura de EEG realizados a sujetos en base a un experimento.

DEAP es un conjunto de datos de código abierto desarrollado por el equipo de investigación de la Queen's University en Marie, Londres [3]. Grabó principalmente las señales fisiológicas multimodales producidas por 32 voluntarios bajo el estímulo de los videos previamente seleccionados. Las señales fisiológicas multimodales incluyen el EEG y las señales fisiológicas periféricas. Cada voluntario veía 40 videos de un minuto de duración. Mientras se presentaba cada video, el EEG y las señales fisiológicas periféricas de los voluntarios se registraron sincrónicamente. Cabe señalar que el EEG se registró en 32 sitios. Al finalizar la captura de las señales EEG, cada participante evaluó los videos utilizando el método SAM [4] de excitación, valencia, gusto y dominio en una escala de 1-9.

Como referencia DEAP utilizó la escala de excitación de valencia de Russell para describir cuantitativamente las emociones. En esta escala, cada estado emocional puede colocarse en un plano bidimensional con excitación y valencia como los ejes horizontal y vertical. Si bien la excitación y la valencia explican la mayor parte de la variación en los estados emocionales, también se puede incluir una tercera dimensión de dominación en el modelo [5].

En este estudio, solo nos enfocamos en las escalas de excitación y valencia. Por lo tanto, se puede construir un modelo emocional bidimensional (ilustrado en la Figura 1), donde las dos dimensiones son excitación y valencia, respectivamente.

DATOS DEL EXPERIMENTO	
Cantidad de participantes	32
Cantidad de videos	40
Escala	Excitación
	Valencia
	Dominio
	Gusto
Valores de las escalas	Familiaridad
	Familiaridad: Discreto 1-5 Otros: Continuo 1-9

TABLE I

RESUMEN CONTENIDO BASE DE DATOS

(1) <http://www.eecs.qmul.ac.uk/>

## IV. MARCO TEÓRICO

### A. Preprocesamiento

La señal se muestrea a una frecuencia de muestreo de 128 Hz. Una frecuencia de muestreo más baja reduce el tiempo de procesamiento para el cálculo de parámetros de características. La electrooculografía (EOG) se elimina porque el movimiento del ojo es la principal fuente de ruido. Se aplica un filtro de paso de banda para eliminar ruidos de menos de 4 Hz o más de 45 Hz. La señal de EEG sin ruido se segmenta en una ventana de tiempo de 6 segundos. Como la frecuencia de muestreo es de 128 Hz, después de la segmentación, el número total de segmentos para todo este proyecto es  $10 \times 32 \times 40 \times 32 = 409600$ . Todas las partes pasaron por el proceso de extracción de características y el 30% de los segmentos se seleccionaron para ser el conjunto de aprendizaje para el clasificador, y el 70% están en el conjunto de prueba. [6]

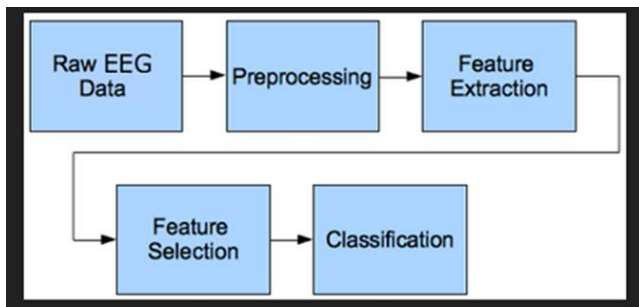


Fig. 1. Flujo para la correcta clasificación de las señales EEG en emociones, utilizando el método de Russell.

### B. Metodología de clasificación

Siendo DEAP una base de datos de referencia para señales de EEG etiquetadas de libre uso, hay muchos investigadores que otorgan su implementación de clasificación de dichas señales EEG. Se seleccionó un método de clasificación que presenta una precisión superior al 98% y que utiliza el método de clasificación SVM para ponderar Valencia y Excitación. [2]

El mismo realiza los siguientes pasos en un programa realizado con Py:

1. Lectura del dataset (Obtenido de la base de datos DEAP)
2. Extracción de características principales
3. Reducción de la dimensión
4. Entrenamiento del modelo
5. Predicción de valencia y excitación

Como resultado de la ejecución del algoritmo, se obtendrá un valor entre 1 y 9 para Excitación y otro para Valencia.

### C. Valores de Valencia y Excitación

Estos términos son conceptos estandarizados al momento de hablar de investigaciones en el área de las emociones.

Mehrabian y Russell introdujeron el placer, la excitación y el dominio como tres dimensiones emocionales independientes

Concibieron el placer como un continuo que va desde el dolor extremo o la infelicidad hasta la felicidad extrema y usaron adjetivos como feliz-infeliz, satisfecho-molesto y satisfecho-insatisfecho para definir el nivel de placer de una persona. La excitación se concibió como una actividad mental que describe el estado de los sentimientos a lo largo de una sola dimensión que va desde el sueño a la excitación excitada y vinculada a adjetivos como estimulación relajada, excitada, calmada, despierta y somnolienta para definir la excitación. La dominación estaba relacionada con los sentimientos de control y el grado en que un individuo se siente restringido en su comportamiento. Para definir el grado de dominio, Mehrabian y Russell utilizaron un continuo que va desde el dominio hasta la sumisión con adjetivos tales como control, influencia y autonomía. Mehrabian (1996) mencionó el sustantivo "relajación" como indicador de las tres dimensiones de placer, excitación y dominio. Sin embargo, si bien dominio es una variable que se puede tener en cuenta para darle más precisión al método propuesto, en esta investigación no será tenido en cuenta. En la figura 2 se puede observar un gráfico de dos dimensiones Valencia y Excitación como ejes principales que definen el estado de ánimo a partir de sus valores.



Fig. 2. Gráfico de dos dimensiones con Valencia y Excitación como ejes.

### D. Clasificador SVM

SVM es un conjunto de algoritmos de aprendizaje supervisado desarrollado que utilizaremos para clasificar la salida del EEG.

Primeramente, es necesario tener datos de entrenamiento para que el algoritmo sepa cómo tratar los datos para predecir la salida. En nuestro caso los datos de entrenamiento serán los previamente descriptos obtenidos de la base de datos DEAP. Se entrenará el modelo para que a través de la entrada - 32 canales del EEG - cotejando la salida con los datos pertenecientes al mismo experimento. Luego de este entrenamiento podremos obtener la salida de cualquier lectura EEG, logrando ponderar el resultado de Excitación y Valencia para valores entre 0 y 9.

(2) <https://github.com/Raghav714/EEG-Emotion-classification> para describir el estado de sentimiento de las personas [7].

Como se mencionó, el presente clasificador tiene varias metodologías que derivan en la clasificación. Más adelante explicaremos cuál será la utilizada para nuestra aplicación [8]

### E. Correlación de las características

Para poder encontrar una relación entre los valores de Excitación y Valencia obtenidos como salida del proceso anterior y la música que describirá nuestro estado de ánimo, tomamos como definición el trabajo realizado por Stefan K. EhrlichID1 et. al [9], quienes determinaron que 5 parámetros estructurales de la música tales como harmonic, mode, tempo, rhythmicroughness, overallpitch, and relative loudness of subsequent notes, tienen un impacto directo en la respuesta emocional de los individuos expresados en Excitación y Valencia.

De esta manera, llegaron a la siguiente conclusión:

$$\text{tempo} : \text{note}_{dur} = 0.3 - \text{aro} * 0.15 \in \mathbb{R} \quad (1)$$

$$\text{rhythm} : p(\text{note} = 1) = \text{aro} \quad (2)$$

$$\text{loudness} : \text{note}_{vol} = \text{unif}\{50, 40 * \text{aro} + 60\} \in \mathbb{N} \quad (3)$$

$$\text{pitch} : \text{note}_{reg} = \begin{cases} p(C3) = 2 * \text{val} & \text{if } \text{val} < 0.5 \\ p(C5) = 2 * (\text{val} - 0.5) & \text{if } \text{val} \geq 0.5 \\ C4 & \text{otherwise} \end{cases} \quad (4)$$

$$\text{mode} = 7 - (6 * \text{val}) \in 1, \dots, 7 \in \mathbb{N} \quad (5)$$

Fig. 3. Ecuaciones utilizadas para la transformación de Valencia y Excitación a variables características de la música.

## V. DESARROLLO

Para el desarrollo de la aplicación decidí dividir el proceso en 3 etapas de desarrollo, en donde cada uno contaba con una entrada y una salida. Para la primera etapa fue necesaria la recopilación de información sobre EEG – cómo se realizan los experimentos, cuáles son las variables, las convenciones estándares de uso, y cuál es el formato de salida. Esta salida es primordial porque será la entrada de la segunda etapa: entrenamiento del modelo. En esta etapa fue necesario indagar la existencia y performance de varios métodos clasificación.

### A. Extracción de características principales

Con la librería de sklearn utilizamos el clasificador SVM para determinar la salida de Excitación y Valencia de la lectura EEG. Para esto primero es necesario entrenar el modelo con datos conocidos (en este caso los mencionados extraídos de la base de datos DEAP). Luego de entrenar nuestro modelo podemos conocer los valores de excitación y valencia de la lectura EEG que deseemos (Figura 4).

```
train_x =
np.genfromtxt('train.csv', delimiter=',')
f = open("labels_0.dat", "r")
for i in f:
```

```
train_y.append(i)
train_y = np.array(train_y).astype(np.float)
train_y = train_y.astype(np.int)
train_x = np.array(train_x)
clf = svm.SVC()
clf.fit(train_x, train_y)
predict_val = clf.predict(train_x)
...
predict_al = clf1.predict(train_x)
```

Fig. 4. Ejemplo de código extraído para precedir valores de Valencia y Excitación.

Siendo train\_x los valores de entrada de los 32 canales del EEG, y train\_y los resultados guardados en labels\_0.dat, pertenecientes al resultado del experimento realizado por DEAP.

Clf predice la salida de Excitación, mientras que de manera análoga Clf predice la correspondiente a Valencia.

### B. Definición de parámetros

Al definir la correlación entre los valores extraídos de la clasificación SVM (Excitación y Valencia) y los pertenecientes a la estructura de la música, resta realizar la búsqueda de canciones que cumplan con este patrón estructural.

Para realizar dicha búsqueda se implementó un sistema basado en la API facilitada por Spotify, que cuenta con metadata de las canciones tales como *loudness*, *danceability*, *style*, *entre otros*. Nuestros parámetros de búsqueda serán los resultados de las ecuaciones 1,2,3,4,5 que serán denominados “valores objetivos” y se determinará un rango en el que se realizará la búsqueda. Por esta razón, la búsqueda de dicho patrón no tendrá como resultado una única canción, sino varias.

### C. Herramienta de búsqueda

Para realizar la búsqueda se utilizará la API facilitada por Spotify que nos permite a través realizar la búsqueda de canciones a través de un servicio con principios REST y que devuelve un documento JSON con información sobre el álbum, el artista, canciones, o su metadata (que utilizaremos para nuestra aplicación). Se accede a los recursos de datos a través de solicitudes HTTPS estándar en formato UTF-8 a un punto final denominado API.

Reemplazando en las siguientes fórmulas de código por los valores procesados de excitación y valencia del EEG, obtenemos los valores con los que haremos la búsqueda en la API de Spotify.

```
target_tempo=(0.3-valencia*0.15)*200
target_loudness=40*excitacion-60
target_mode=7-6*valencia
target_rhythm=excitacion
```

Fig. 5. Ejemplo de código con las ecuaciones utilizadas para transformar valores de Excitación y Valencia a variables características de la música.

Con los valores de búsqueda realizamos la consulta que nos dará como retorno un JSON dentro de la variable “results” con canciones que cumplen estas definiciones. Su resultado será el

observado en la figura 7, en donde se aprecian las canciones propuestas por la aplicación.

```
results = sp.recommendations(seed_artists=None,
seed_genres=["electro"], seed_tracks=None,
limit=15, country=None,
                             target_valence=target_valence,
                             target_tempo=target_tempo,
                             target_loudness=target_loudness,
                             min_valence=min_valence,
                             max_valence=max_valence,
                             target_mode=target_mode
                             )
```

Fig. 6. Ejemplo de código para búsqueda de resultados en API de spotify.

Como default utilizaremos un género estándar en el cual nos basaremos para realizar la búsqueda.

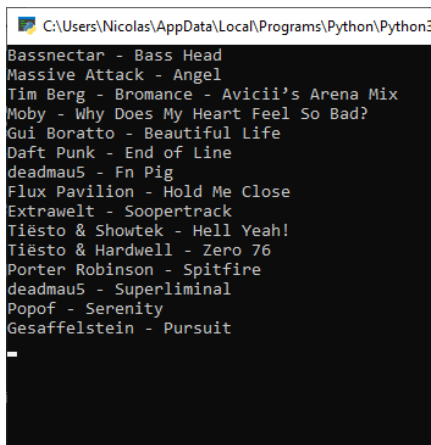


Fig. 7. Canciones recomendadas en base a las lecturas EEG.

## VI. CONCLUSIÓN

### A. Observaciones

El cerebro es el órgano más complejo conocido y por conocer. Hace que actuemos como actuamos, pensemos como pensamos, y seamos quienes somos. Mucho camino queda por recorrer para entenderlo. “Each neuron may be connected to up to 10,000 other neurons, passing signals to each other via as many as 1,000 trillion synapses.” [10].

El cerebro puede hablar y lo hace a través de nuestros labios. El cerebro puede bailar y lo hace a través de nuestro cuerpo. El cerebro puede reír y lo hace a través de nuestro rostro. El cerebro ya habla por sí solo pero siempre tiene un interlocutor.

Teniendo en cuenta todas las complejidades con las que el cerebro cuenta y que desemboca en complejos procesos de interpretación de estudios, la aplicación que se diseñó y desarrolló en el presente trabajo explica todos los pasos por los que se transitó para convertir señales eléctricas en una canción a través del desarrollo de una aplicación. Toma los datos extraídos de un EEG, los procesa, los limpia, los analiza, y en última instancia los evalúa para elegir por nosotros una canción que sea acorde al estado emocional del sujeto en el

momento medido.

### B. Trabajos futuros

La última etapa de la aplicación analiza los datos en un momento particular del estudio EEG y elige la canción más adecuada a nuestro estado de ánimo en ese instante. En base a los resultados completos de un estudio EEG, desde su comienzo a fin (sin importar la duración del mismo), sería posible realizar un espectrograma y que este mismo sea el espectrograma de nuestra canción, o en su defecto tomar los puntos clave del espectrograma y compararlos con espectrogramas de canciones ya existentes para que la aplicación tenga resultados aún más certeros.

## VII. REFERENCIAS

- [1] Iris Bakker, Theo van der Voordt, Peter Vink, Jan de Boon “Pleasure, Arousal, Dominance: Mehrabian and Russell revisited”
- [2] Hasmina Hassan, Zunairah Haji Murat, Valerie Ross and Norlida Buniyamin, “A Preliminary Study on the Effects of Music on Human Brainwave”, p176
- [3] Koelstra S., Muehl C., Soleymani M., et al. DEAP: a database for emotion analysis using physiological signals. *IEEE Transaction on Affective Computing*. 2012;3(1):18–31. doi: 10.1109/t-affc.2011.15.
- [4] J. D. Morris, “SAM: the self-assessment manikin. An efficient cross-cultural measurement of emotional response,” *Journal of Advertising Research*, vol. 35, no. 8, pp. 63–68, 1995.
- [5] J. A. Russell, “A circumplex model of affect,” *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161–1178, 1980
- [6] Kairui Guo, Henry Candra, Hairong Yu, Huiqi Li, Hung T. Nguyen and Steven W. Su “EEG-based Emotion Classification Using Innovative Features and Combined SVM and HMM Classifier”
- [7] Iris Bakker, Theo van der Voordt, Peter Vink, Jan de Boon “Pleasure, Arousal, Dominance: Mehrabian and Russell revisited”
- [8] Yuan-Pin Lin, Chi-Hong Wang, Tien-Lin Wu, Shyh-Kang Jeng and Jyh-Horng Chen, “EEG-based emotion recognition in music listening: a comparison of schemes for multiclass support vector machine” *IEEE Trans. Biomedical Engineering*, 2010
- [9] Stefan K. Ehrlich ID1\*, Kat R. Agres, Cuntai Guan, Gordon Cheng “A closedic-based brain-computer interface for emotion mediation”
- [10] Jiawei Zhang, “Basic Neural Units of the Brain: Neurons, Synapses and Action Potential”

## VIII. BIOGRAFÍA



**Nicolás Kis** nacido en Buenos Aires, Argentina, el 17 de marzo de 1991. Estudió en el colegio Pestalozzi donde desarrolló su conocimiento en el habla alemán en inglés, obteniendo el título bachiller bilingüe en ciencias y letras. Actualmente finalizando la carrera de Ingeniero Informático en la facultad de Palermo.

Comenzó su carrera laboral trabajando para Volkswagen Argentina donde se desempeñó en el área de calidad durante 7 años.

Luego trabajó en Softland Argentina durante 1 año, y actualmente desempeña sus tareas para el laboratorio alemán Boehringer-Ingelheim.

Luego de renunciar a Volkswagen Argentina realizó un intercambio laboral en la ciudad de Málaga, España.